基于深度关联度量的简单在线实时追踪

Nicolai Wojke†, Alex Bewley, Dietrich Paulus †

科布伦茨-兰道大学†，昆士兰科技大学

摘要

简单在线实时跟踪(SORT)是一种注重简洁有效算法的多目标跟踪实用方案。本研究通过整合外观信息来提升SORT算法的性能。此项改进使系统能够更长时间地处理目标遮挡情况，有效降低了身份切换次数。遵循原始框架的设计理念，我们将大部分计算复杂度转移至离线预训练阶段：在大规模行人重识别数据集上学习深度关联度量。在线应用过程中，通过在视觉外观空间执行最近邻查询来实现测量值与轨迹的关联。实验评估表明，我们的改进使身份切换次数减少45%，在高帧率条件下实现了具有竞争力的综合性能。

索引术语—计算机视觉，多目标跟踪，数据关联

1. 引言

近年来，随着目标检测技术的进步，基于检测的跟踪已成为多目标跟踪领域的主流范式。在该范式下，通常通过处理整批视频数据的全局优化问题来获取目标轨迹。例如流网络公式[1,2,3]和概率图模型[4,5,6,7]已成为此类方法的流行框架。但由于采用批处理方式，这些方法无法适用于需要实时获取目标身份信息的在线场景。

更传统的方法包括多假设跟踪(MHT)[8]和联合概率数据关联滤波器(JPDAF)[9]。这些方法采用逐帧数据关联策略：JPDAF通过加权各测量值的关联似然度生成单一状态假设；MHT则跟踪所有可能假设，但必须采用剪枝方案以保证计算可行性。这两种方法近期在基于检测的跟踪场景中得以重新应用[10,11]，并展现出良好性能。然而，这些方法的性能提升是以更高的计算复杂度和实现难度为代价的。

简易在线实时追踪(SORT)算法[12]是一种

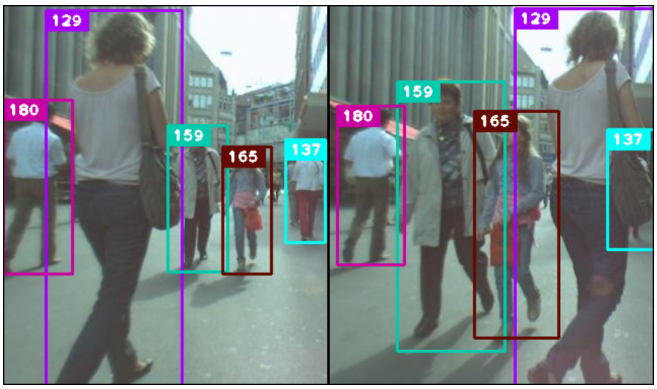

图1：我们的方法在MOT挑战数据集[15]上的典型输出结果，展示了频繁遮挡常见跟踪场景中的表现。

一个更简单的框架，在图像空间执行卡尔曼滤波，并使用匈牙利算法通过测量边界框重叠度的关联度量进行逐帧数据关联。这种简单方法在高帧率下实现了优异性能。在MOT挑战数据集[13]上，采用最先进行人检测器[14]的SORT算法在标准检测任务中的平均排名高于MHT方法。这不仅凸显了目标检测器性能对整体跟踪结果的影响，从实践者的角度来看也是一个重要发现。

虽然SORT算法在跟踪精度和准确性方面整体表现良好，但其身份标识切换次数相对较高。这是因为该算法采用的关联度量仅在状态估计不确定性较低时表现准确，导致其在处理遮挡场景（尤其是前视角相机场景中常见的遮挡情况）时存在明显缺陷。我们通过引入融合运动与外观信息的智能度量方法解决了这一问题，具体采用在大型行人重识别数据集上训练过的卷积神经网络（CNN）来区分不同行人。该网络的集成显著提升了系统对漏检和遮挡情况的鲁棒性，同时保持其易于实现、高效运行且适用于在线场景的特点。我们公开了算法代码与预训练的CNN模型，以促进研究实验和实践应用开发。

arXiv:1703.07402v1 [cs.CV] 20-

2. 基于深度关联度量的排序方法

我们采用传统的单假设跟踪方法，结合递归卡尔曼滤波和逐帧数据关联技术。下一节将详细描述该系统的核心组成部分。

2.1. 轨迹处理与状态估计

该轨迹处理与卡尔曼滤波框架基本沿用了文献[12]中 的原始设计。我们设定了一个非常普遍的追踪场景：相机未经过校准且无法获取自身运动信息。尽管这些条件对滤波框架构成了挑战，但这是当前多目标追踪基准测试中最常采用的配置[15]。因此，我们的追踪场景定义在八维状态空间$(u, v, \gamma, h, \dot{x}, \dot{y}, \dot{\gamma}, \dot{h})$上，该空间包含边界框中心位置$(u, v)$、宽高比$\gamma$、高度$h$及其在图像坐标系中的对应速度。我们采用标准卡尔曼滤波器，配备恒定速度运动模型和线性观测模型，并将边界坐标(u, v, γ, h)作为物体状态的直接观测值。

对于每个轨迹k，我们统计自上次成功测量关联a_k以来的帧数。该计数器在卡尔曼滤波器预测过程中递增，并在轨迹与测量值关联时重置为0。超过预设最大存活期}的轨迹被视为已离开场景，并从轨迹集中删除。对于无法与现有轨迹关联的每个检测结果，会初始化新的轨迹假设。这些新轨迹在前三帧被归类为暂定状态。在此期间，我们期望在每个时间步都能实现成功的测量关联。未能在前三帧内成功与测量值关联的轨迹将被删除。

2.2. 分配问题

解决预测卡尔曼状态与新到测量值之间关联的常规方法是构建一个分配问题，该问题可通过匈牙利算法求解。在此问题框架中，我们通过结合两种相适配的度量指标，将运动信息与外观特征信息进行融合。

为融合运动信息，我们采用预测卡尔曼状态与新到测量值之间的（平方）马哈拉诺比斯距离：

$$d^{(1)}(i,j) = (\boldsymbol{d}_j - \boldsymbol{y}_i)^{\mathrm{T}} \boldsymbol{S}_i{}^{-1} (\boldsymbol{d}_j - \boldsymbol{y}_i), \tag{1}$$

其中，我们将第i条轨迹分布在测量空间的投影记为}，第j个边界框检测记为$\boldsymbol{d}_j$。马氏距离通过衡量状态估计的不确定性来考虑检测结果与平均轨迹位置之间的标准差。此外，通过该度量标准，可基于逆χ^2分布计算出95%置信区间的马哈拉诺比斯距离阈值，从而排除不合理的关联可能性。我们使用指示变量来表示这一判定结果。

$$b_{i,j}^{(1)} = \mathbb{1}[d^{(1)}(i,j) \leq t^{(1)}] \tag{2}$$

当第i个轨迹与第j个检测之间的关联成立时，该值评估为1。在我们的四维测量空间中，对应的马哈拉诺比斯阈值为$t^{(1)} = 9.4877$.。

当运动不确定性较低时，马氏距离是一种合适的关联度量指标，但在我们的图像空间问题建模中，通过卡尔曼滤波框架获得的预测状态分布仅能提供目标位置的粗略估计。特别是未考虑的相机运动可能导致图像平面上的快速位移，使得马氏距离在遮挡场景中成为信息量不足的跟踪度量指标。因此，我们在分配问题中引入了第二项度量指标。针对每个边界框检测$\boldsymbol{d}_j$，我们使用}计算外观描述符$\boldsymbol{r}_j$。此外，我们为每个轨迹k维护一个包含最近$L_k = 100$个已关联外观描述符的图库$\mathcal{R}_k = \{\boldsymbol{r}_k^{(i)}\}_{k=1}^{L_k}$。随后，我们的第二项度量指标通过计算外观空间中第$i$个轨迹与第$j$个检测之间最小余弦距离来实现：

$$d^{(2)}(i,j) = \min\{1 - \boldsymbol{r}_j{}^{\mathrm{T}} \boldsymbol{r}_k^{(i)} \mid \boldsymbol{r}_k^{(i)} \in \mathcal{R}_i\}. \tag{3}$$

我们再次引入一个二元变量，用以根据该度量标准判断关联是否可接受。

$$b_{i,j}^{(2)} = \mathbb{1}[d^{(2)}(i,j) \leq t^{(2)}] \tag{4}$$

并在独立的训练数据集上为该指标确定一个合适的阈值。实际操作中，我们采用预训练的卷积神经网络来计算边界框外观描述符，该网络架构的具体说明详见第2.4节。

综合而言，这两种度量标准通过服务于分配问题的不同方面而相互补充。一方面，马哈拉诺比斯距离基于运动提供可能的目标位置信息，这对短期预测特别有用。另一方面，余弦距离考虑外观信息，当运动特征难以区分时，这对长期遮挡后的身份恢复尤为有效。为构建关联问题，我们采用加权求和的方式将两种度量标准相结合。

$$c_{i,j} = \lambda\, d^{(1)}(i,j) + (1-\lambda) d^{(2)}(i,j) \tag{5}$$

当关联处于两个指标的选通区域内时，我们称该关联为可接受的：

$$b_{i,j} = \prod_{m=1}^{2} b_{i,j}^{(m)}. \tag{6}$$

表1 匹配级联

输入：轨道索引 $\mathcal{T} = \{1,\ldots,N\}$, 检测索引 $\mathcal{D} = \{1,\ldots,M\}$, 最大年龄 $A_{\max}$

1: 使用公式5计算成本矩阵$\boldsymbol{C} = [c_{i,j}]$
2: 使用公式6计算门矩阵$\boldsymbol{B} = [b_{i,j}]$
3: 初始化匹配集$\mathcal{M} \leftarrow \emptyset$
4: 初始化未匹配检测集合$\mathcal{U} \leftarrow \mathcal{D}$
5: 对于$n \in \{1,\ldots,A_{\max}\}$执行循环
6: 按年龄选择音轨 $\mathcal{T}_n \leftarrow \{i \in \mathcal{T} \mid a_i = n\}$
7: $[x_{i,j}] \leftarrow \text{min_cost_matching}(\boldsymbol{C}, \mathcal{T}_n, \mathcal{U})$
8: $\mathcal{M} \leftarrow \mathcal{M} \cup \{(i,j) \mid b_{i,j} \cdot x_{i,j} > 0\}$
9: $\mathcal{U} \leftarrow \mathcal{U} \setminus \{j \mid \sum_i b_{i,j} \cdot x_{i,j} > 0\}$
10: 循环结束
11: 返回 $\mathcal{M}$,$\mathcal{U}$

每个指标对关联总成本的影响可通过超参数λ.进 行 调控。实验发现，当存在显著相机运动时，设定$\lambda = 0$是合理的选择。在此配置下，关联成本项仅使用外观信息，但马氏距离门限仍会基于卡尔曼滤波器推断的物体可能位置来排除不可行的匹配方案。

2.3. 匹配级联

我们引入了一种级联方法来解决一系列子问题，而非通过全局分配问题来求解测量到轨迹的关联。为阐明此方法的动机，考虑以下场景：当目标被长时间遮挡时，后续卡尔曼滤波预测会增大目标位置的不确定性。因此，概率质量在状态空间中扩散，观测似然函数的峰值特性减弱。直观而言，关联度量应通过增加测量到轨迹的距离来适应这种概率质量的扩散。但反直觉的是，当两条轨迹竞争同一检测点时，马氏距离反而偏好更大的不确定性——因为它实际上会缩小任何检测点到投影轨迹均值的标准差距离。这种不良特性会导致轨迹碎片化加剧和轨迹稳定性下降。因此，我们采用优先处理更频繁出现目标的匹配级联机制，将概率扩散的概念编码到关联似然函数中。

清单1概述了我们的匹配算法。作为输入，我们提供轨迹索引集$\mathcal{T}$和检测索引集$\mathcal{D}$以及最大生命周期$A_{\max}$。在第1行和第2行中，我们计算关联成本矩阵和允许关联矩阵。随后我们遍历轨迹生命周期n，为不同生命周期的轨迹求解线性分配问题。第6行中我们筛选出过去n帧内未与任何检测关联的轨迹子集$\mathcal{T}_n$。第7行我们求解$\mathcal{T}_n$中轨迹与未匹配检测$\mathcal{U}$.之间的线性分配问题。

名称	补丁大小/步长	输出尺寸
会话 1	$3 \times 3/1$	$32 \times 128 \times 64$
卷积层2	$3 \times 3/1$	$32 \times 128 \times 64$
最大池化3	$3 \times 3/2$	$32 \times 64 \times 32$
残留4	$3 \times 3/1$	$32 \times 64 \times 32$
残留5	$3 \times 3/1$	$32 \times 64 \times 32$
残留6	$3 \times 3/2$	$64 \times 32 \times 16$
残差7	$3 \times 3/1$	$64 \times 32 \times 16$
残留8	$3 \times 3/2$	$128 \times 16 \times 8$
残余9	$3 \times 3/1$	$128 \times 16 \times 8$
Dense 10		128
批次和ℓ_2也不 规范化		128

表1：CNN架构概览。最终批次与ℓ_2归一化将特征投影至单位超球面。

在第8行和第9行，我们更新匹配集合和未匹配检测集合，并在第11行完成处理后返回这些结果。需要注意的是，这种级联匹配机制会优先处理年龄较小的轨迹，即最近出现过的轨迹。

在最终匹配阶段，我们对年龄为$n = 1$的未确认轨迹和未匹配轨迹集合，采用原始SORT算法[12]中提出的交并关联方法。这有助于应对突然的外观变化（例如由静态场景几何部分遮挡引起的情况），并提升对错误初始化的鲁棒性。

2.4. 深度外观描述符

通过简单的最近邻查询而无需额外的度量学习，我们的方法要成功应用，需要在线跟踪实际应用之前，离线训练出具有良好区分度的特征嵌入。为此，我们采用了一个在大规模行人重识别数据集[21]上训练的卷积神经网络，该数据集包含1,261名行人的超过1,100,000张图像，使其非常适用于人员跟踪场景中的深度度量学习。

我们的网络CNN架构如表1所示。该网络采用宽残差网络[22]结构，包含两个卷积层和六个残差块。维度为1-28的全局特征图在稠密层10中计算得出。最终通过批处理与ℓ_2归一化将特征投影到单位超球面，使其与我们的余弦外观度量兼容。整个网络共包含2,800,864个参数，在Nvidia GeForce GTX 1050移动GPU上单次前向传播处理32个边界框仅需约30毫秒。因此，只要配备现代G P U，该网络非常适合在线跟踪任务。虽然训练流程的详细说明不在本文讨论范围内，但我们已在GitHub仓库提供了预训练模型。

		MOTA ↑	MOTP ↑	MT ↑	机器学习 ↓	ID ↓	调频 ↓	FP ↓	FN ↓	运行时间 ↑
KDNT [16]	批次	68.2	79.4	41.0%	19.0%	933	1093	11479	45605	0.7赫兹
LMP_p [17]	批处理	71.0	80.2	46.9%	21.9%	434	587	7880	44564	0.5 Hz
MCMOT_HDM [18]	批次	62.4	78.3	31.5%	24.2%	1394	1318	9855	57257	35 Hz
NOMTwSDP16 [19]	批处理	62.2	79.6	32.5%	31.1%	406	642	5119	63352	3 赫兹
EAMTT [20]	在线	52.5	78.8	19.0%	34.9%	910	1321	4407	81223	12 Hz
POI [16]	ONLINE	66.1	79.5	34.0%	20.8%	805	3093	5061	55914	10 赫兹
分类 [12]	在线	59.8	79.6	25.4%	22.7%	1423	1835	8698	63245	60 Hz
深度 SORT（本系统）	ONLINE	61.4	79.1	32.8%	18.2%	781	2008	12852	56668	40 赫兹

表2：MOT16挑战赛[15]的追踪结果。我们与其他采用非标准检测方法的已发表成果进行对比。完整结果表可于挑战赛官网查阅。标注的方法使用了由[16]提供的检测数据。

故事1以及一个可用于生成特征的脚本。

3. 实验

我们在MOT16基准测试[15]中评估了跟踪器的性能。该基准测试通过七个具有挑战性的测试序列来评估跟踪性能，包括移动摄像机的前视角场景和俯视监控场景。我们的跟踪器采用Yu等人[16]提供的检测结果作为输入，他们通过在公共和私有数据集上训练Faster RCNN模型获得了卓越性能。为公平比较，我们使用相同检测结果重新运行了SORT算法。

对测试序列的评估使用了$\lambda = 0$和$A_{\max} = 30$帧。如文献[16]所示，检测结果的置信度分数阈值设定为0.3。我们方法的其余参数通过在基准测试提供的独立训练序列上进行优化得到。评估根据以下指标进行：

- 多目标跟踪准确率（MOTA）：综合衡量整体跟踪精度，涵盖误报、漏报和身份切换等指标[23]。
- 多目标跟踪精确度（MOTP）：基于标注框与报告位置之间的重叠度，评估整体跟踪精确性的综合指标[23]。
- 基本成功跟踪（MT）：至少80%生命周期内保持正确标签的真实轨迹占比。
- 基本丢失目标（ML）：最多仅20%生命周期被成功跟踪的真实轨迹占比。
- 身份切换次数（ID）：同一真实轨迹被报告的身份标识发生变更的次数。
- 轨迹中断次数（FM）：由于检测缺失导致轨迹被中断的累计次数。

我们的评估结果如表2所示。通过适应性改进，我们成功减少了身份切换次数。与SORT算法相比，身份切换次数从1423次降至781次，降幅约为45%。与此同时，由于通过遮挡和漏检时保持目标身份，轨迹碎片化程度略有增加。我们还能观察到大部分被跟踪目标的数量显著增加，而大部分丢失目标的数量有所减少。总体而言，由于外观信息的整合，我们成功在更长遮挡周期中保持了身份一致性。这一结论也可通过我们对补充材料所提供跟踪结果的定性分析得到验证，图1展示了我们跟踪器的示例输出。

我们的方法同样是其他在线跟踪框架的有力竞争者。特别值得注意的是，在保持具有竞争力的MOTA分数、轨迹片段化和假阴性指标的同时，本方法实现了所有在线方法中最少的身份切换次数。当前报告的跟踪精度主要受到较多假阳性检测结果的影响。鉴于假阳性对MOTA分数的总体影响，对检测结果应用更高的置信度阈值可能会大幅提升我们算法的报告性能。但通过跟踪输出的可视化检查发现，这些假阳性主要源于静态场景几何结构中偶发的检测器响应。由于我们设置了相对较大的最大允许轨迹寿命，这些误检更易被关联到目标轨迹中。与此同时，我们并未观察到轨迹在误检点之间频繁跳变的情况。相反，跟踪器通常在报告目标位置处生成相对稳定的静止轨迹。

我们的实现以大约20赫兹的频率运行，其中约一半时间用于特征生成。因此，在配备现代GPU的情况下，该系统仍能保持计算效率并实现实时操作。

4. 结论

我们提出了一种SORT算法的扩展版本，该版本通过预训练的关联度量整合了外观信息。这一扩展使算法能够处理更长时间的遮挡情况，使SORT成为当前先进在线跟踪算法的有力竞争者。同时，该算法仍保持易于实现的特性，并能够实时运行。

1https://github.com/nwojke/deep_sort

5. 参考文献

[1] L. Zhang, Y. Li, and R. Nevatia, “基于网络流的全局数据关联多目标跟踪方法”，发表于《CVPR》，2008年，第1-8页。

[2] H. Pirsiavash, D. Ramanan, and C. C. Fowlkes, “面向可变数量目标跟踪的全局最优贪心算法”，发表于《CVPR》，2011年，第1201-1208页。

[3] J. Berclaz, F. Fleuret, E. T¨uretken, and P. Fua, “基于K最短路径优化的多目标跟踪”，《IEEE模式分析与机器智能汇刊》，第33卷第9期，第1806-1819页，2011年。

[4] B. Yang and R. Nevatia, “在线学习CRF模型的多目标跟踪方法”，发表于《CVPR》，2012年，第2034-2041页。

[5] B. Yang and R. Nevatia, “通过在线学习非线性运动模式与鲁棒外观模型的多目标跟踪”，发表于《CVPR》，2012年，第1918-1925页。

[6] A. Andriyenko, K. Schindler, and S. Roth, “多目标跟踪中的离散-连续优化方法”，发表于《CVPR》，2012年，第1926-1933页。

[7] A. Milan, K. Schindler, and S. Roth, “多目标跟踪中的检测与轨迹级排除机制”，发表于《CVPR》，2013年，第3682-3689页。

[8] D. B. Reid, “多目标跟踪算法”，《IEEE自动控制汇刊》，第24卷第6期，第843-854页，1979年。

[9] T.E. Fortmann, Y. Bar-Shalom, and M. Scheffe, “基于联合概率数据关联的声纳多目标跟踪”，《IEEE海洋工程杂志》*Eng.*，第8卷第3期，第173-184页，1983年。

[10] C. Kim, F. Li, A. Ciptadi, and J. M. Rehg, “多重假设跟踪算法重构”，发表于《ICCV》，2015年，第4696-4-704页。

[11] S.H. Rezatofighi, A. Milan, Z. Zhang, Qi. Shi, An. Dick, and I. Reid, “联合概率数据关联算法重构”，发表于《ICCV》，2015年，第3047-3055页。

[12] A. Bewley, G. Zongyuan, F. Ramos, and B. Upcroft, “简易在线实时跟踪算法”，发表于《ICIP》，2016年，第3464-3468页。

[13] L. Leal-Taix´e, A. Milan, I. Reid, S. Roth, and K. Schindler, “MOTChallenge 2015：面向多目标跟踪的基准测试”，arXiv:1504.01942 [cs]，2015年。

[14] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN：通过区域提议网络实现实时目标检测"，发表于NIPS，2015年。

[15] A. Milan, L. Leal-Taixé, I. Reid, S. Roth, and K. Schindler, "Mot16：多目标跟踪基准测试集"，arXiv预印本arXiv:1603.00831，2016年。

[16] F. Yu, W. Li, Q. Li, Y. Liu, X. Shi, and J. Yan, "Poi：基于高性能检测与外观特征的多目标跟踪"，收录于ECCV。Springer出版社，2016年，第36–42页。

[17] M. Keuper, S. Tang, Y. Zhongjie, B. Andres, T. Brox, and B. Schiele, "多目标联合分割与跟踪的多割优化框架"，arXiv预印本arXiv:1607.06317，2016年。

[18] B. Lee, E. Erdenee, S. Jin, M. Y. Nam, Y. G. Jung, and P. K. Rhee, "基于变点检测的多类别多目标跟踪"，收录于ECCV。Springer出版社，2016年，第68–83页。

[19] W. Choi, "基于聚合局部流描述符的近在线多目标跟踪"，发表于ICCV，2015年，第3029–3037页。

[20] R. Sanchez-Matilla, F. Poiesi, and A. Cavallaro, "基于强弱检测的在线多目标跟踪"，收录于欧洲计算机视觉会议。Springer出版社，2016年，第84–99页。

[21] L. Zheng, Z. Bie, Y. Sun, J. Wang, C. Su, S. Wang, and Q. Tian, "MARS：大规模行人重识别视频基准数据集"，发表于ECCV，2016年。

[22] S. Zagoruyko and N. Komodakis, "宽残差网络"，发表于BMVC，2016年，第1–12页。

[23] K. Bernardin and R. Stiefelhagen, "多目标跟踪性能评估：CLEAR MOT指标"，EURASIP图像与视频处理期刊，第2008卷，2008年。